实验二：OpenMP IVF-Flat 向量检索　实验报告

姓名：杨清徽　　学号：2024201584　　2026 年 11 月

摘要　本报告以”一次查询的成本账” $W(q) = a + b \cdot C(q)$ 为主线：a 是与查询无关的中心选择开销，$b \cdot C(q)$ 是候选扫描开销。先实测这笔账，据此写下 8 条带数字的预测（P1–P8），再用 A–F 六组实验逐条检验。两个事实贯穿全部结果：(1) nprobe=8 时中心选择占 62%，它既不能用 SIMD 加速，batch=1 时也只能串行；(2) 本机（i7-14650HX，8P+8E，WSL2）上同时忙碌的线程会互相拖慢，16 线程时约慢 1.8 倍。大 batch 时 16 线程加速比为 7.4–7.9；单查询时，合规的查询内并行最多 1.23，把中心距离也拆成任务后达到 3.99（作为探索）。8 条预测中 2 条成立，5 条部分成立，1 条被推翻。

1　成本账与预测

数据：本机没有课程的 `/var/dataset`，于是按课程格式自建：texmex SIFT1M（$N = 10^6$，d=128），用 faiss-cpu 1.15.1 在全部库向量上训练 IVF（L=4096）；ground truth 按整数精确距离和 $(distance, id)$ 排序（`--only exact` 的 Recall@10 恰好为 1）。列表长度最短 66、中位数 227、最长 1255；实验取前 Q=1024 个查询，k=10。坐标是 0–218 的整数，前 100 名内有等距的查询占 76%，所以等距在这份数据上是常态。**P0 分阶段计时**（单线程，每个查询计时 5 次取中位数）：每算一个中心约 53.5 ns，每扫一个候选约 59.4 ns，二者只差 11%，说明标量 double 距离受累加依赖链限制，是计算瓶颈而非内存瓶颈。

表 1: 前 1024 个查询的单线程分阶段墙钟时间（合计）。f_{sel} 为中心选择所占比例。

nprobe	C(q)：中位数 / 最大 / 平均	中心选择 (ms)	扫描 (ms)	f_{sel}
1	247 / 1255 / 282	223.6	17.7	0.927
8	2015 / 5704 / 2231	224.7	135.7	**0.623**
32	8132 / 16022 / 8762	231.6	542.5	0.299

表 2: 实验前写入计划的可证伪预测（“部分”指方向对但幅度不符，或只有一半成立）。

#	预测（依据）	实测	判定
P1	omp2、batch=1：$S(16) < 2$（Amdahl 上界 1.55）	最高 1.23（p=4），p=16 时 0.93	成立
P2	中心距离也拆成任务：batch=1 时 $S(16)$ 为 5–10	3.99	部分
P3	batch=64：$S(16) \approx 11$（Lab1：线程速度为串行的 0.71）	7.4–7.9	推翻
P4	按 C(q) 排序后 static：多个 batch 变快，单个 batch 变慢	单个 batch 慢 10–16%；多个 batch 在噪声内	部分
P5	最优 grain：batch=1 呈 U 形；batch=64 越大越快	最优 128–256；batch=64 差异 <3%	部分
P6	nprobe 从 8 降到 1，QPS 只升 1.4–1.8 倍（固定开销 a）	1.59	成立
P7	SIMD：p=1 时整体快 1.3–1.5 倍；nprobe 越大收益越大；p=16 时不超过 p=1	1.24 / 1.52 / 1.04–1.14	部分
P8	std::thread 在 batch=64 时慢 20–30%，随 batch 增大缩小	+0.29 ms/调用；batch=16 时 +28%	部分

2　实现

omp1：`parallel for schedule(runtime)`，每个查询独立完成全部步骤，团队大小为 $\min(p, \text{batch})$。调度消融（p=16，batch=64）：static 58.4 ms，guided 54.9 ms，**dynamic:1 54.1 ms**（选用）。

omp2：每次 batch 调用只建一个团队，由 `parallel+single` 为每个查询生成任务 T_q。T_q 依次：① 调用公共的 `select_lists`；② 把选中的列表首尾相接成虚拟区间 $[0, C)$，用前缀和 `off[]` 定位；③ 按 grain 切块（块可跨列表，长列表也会被拆开，每个候选恰好计算一次）；④ 用 `taskloop grainsize(1)` 为每块生成任务，块内维护局部 `TopK`，写入 `part[b·k,(b+1)·k)`；⑤ taskloop 的隐式 taskgroup 结束后由 T_q 合并（跳过 id=−1 的填充项）。**每块保留 k 个就够**：若 e 在全局前 k 名，比它更好的元素不超过 $k-1$ 个，块内自然也不超过，故 e 必在本块前 k 名（前提：$(distance, id)$ 为全序、id 唯一）。**数据归属**：`lists`、`off`、`part` 由 T_q 持有；块任务只读前两者，块 b 只写自己的 k 个位置；T_q 在 taskloop 结束后读取，返回时释放。**陷阱**：这些局部变量在嵌套 taskloop 中默认是 firstprivate，会被每块复制一份、写入丢失，所以代码用 `default(none)`，只把裸指针 firstprivate 进去。小任务阈值经消融证明有害（§4.3），因此 cutoff=0。

omp2+拆分（探索，CP1 决定）：4096 个中心每 256 个一块拆成任务，仍用公共的 `l2_distance_scalar` 计算，再用同一个全序比较器 `better` 做 `partial_sort`。选出的列表与 `select_lists` 逐项相同、完整检查全部通过，但没有直接调用 `select_lists`，所以正文主表只用 omp2。

SIMD：`--dist` 切换 4 种候选距离（取值写入 CSV）：scalar（公共函数，double）、f32（float 累加，无 `omp simd`）、simd64（double + `omp simd reduction`）、simd32（float + `omp simd reduction`）；Top-k 更新放在距离函数之外。float32 是精确的：每项 $\leqslant 218^2$，128 维之和 $\leqslant 6.08 \times 10^6 < 2^{24}$，且每项非负，任意累加顺序的部分和都是 float 能精确表示的整数，结果与 double 逐位相同；该前提在计时之外检查，不满足就拒绝使用。

std::thread：每次调用新建 $\min(p, \text{batch}) - 1$ 个线程，返回前 join，区间划分与 libgomp 的 static 相同，只用公共的中心选择和标量距离。**omp3**：每个候选都进 `critical` 更新共享 Top-k，作为反面对照。

3 环境、比较条件与正确性

环境：i7-14650HX（8P+8E，16 核 24 线程，L3 30 MB），WSL2 内核 6.6.87.2，内存 7.6 GiB，g++ 13.3.0 + libgomp，插电、电源模式”最佳性能”；P=16，大 batch 取 4P=64。**编译**：统一 `-O3 -std=c++17 -fopenmp -pthread`，不加 `-ffast-math`；`-march=native` 只在实验 E 作对照。**绑定**：都不绑核，CPU 集合 0–23（Lab1 测得 p≤16 时绑核影响在噪声内，且 OMP 绑定变量管不到 std::thread）。**计时**：每个配置单独一个进程，预热 1 次、正式 10 次取中位数；共 3 轮（E 为 5 轮），取各轮中位数的中位数，配置顺序随机；计时只包住检索函数调用（含线程管理与同步）；S 的分母始终是串行 IVF。

正确性：`student_tests` 在 5 组小数据上（空列表、候选不足 k、大量等距、超长列表、非整数坐标）覆盖全部策略、4 种距离、线程 {1,2,3,7,16,24}、batch {1,2,5,Q}、grain {1,2,64,2^{20}}、cutoff、k=1、nprobe=1 与 nprobe=nlist，**8950 种配置**与串行逐位相同（距离和 id 都用 == 比较），ASan+UBSan 构建同样通过；3 个人为注入的错误都被抓到。真实数据上 **101 次完整检查全部 PASS**（ASan 构建同样），并行版本的 Recall 与串行相同。

4 结果：逐项核对成本账

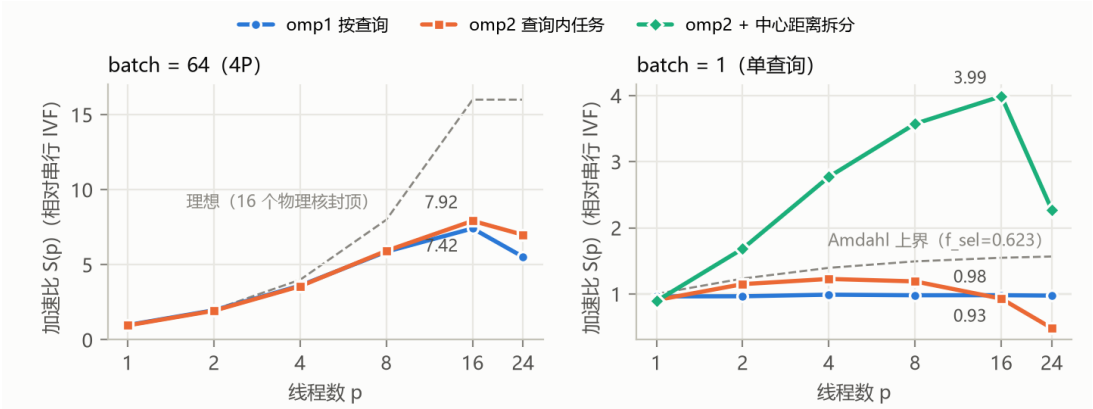


图 1: 实验 A：串行 T 为 381.2 ms（batch=64）和 378.3 ms（batch=1）。右图虚线是用 $f_{sel} = 0.623$ 算出的 Amdahl 上界。完整数据见附录 A。

4.1 线程扩展（实验 A）

batch=64：两种策略几乎重合，p=16 时 S 为 7.42（omp1）和 7.92（omp2），$E \approx 0.5$；p=24 时变差、波动大（被其他进程抢占）。**P3 落空的原因不是负载不均**：统计构建显示 p=16 时忙碌时间的 max/mean 只有 1.04，但 16 个线程的工作时间之和是串行的 1.84–2.0 倍；改用 nprobe=1 后中心常驻缓存，每查询的中心选择仍从 224 µs 涨到 401 µs，所以也不是 DRAM 带宽。结论是**同时忙碌的线程会互相拖慢**（可能来自 E 核、全核睿频下降或 SMT 共享，无硬件计数器无法区分）。

batch=1：omp1 只有 1 个线程工作，$S \approx 0.97$；omp2 最高 1.23（p=4），p=16 时 0.93，始终低于 Amdahl 上界（P1）。定位原因：令 grain=4096 使每个查询只剩 1 个任务、任一时刻只有 1 个线程在算，p=16 时墙钟 546.7 ms（比 p=1 多 42%），干活线程每查询要算 542 µs（串行 371 µs）；改成 `OMP_WAIT_POLICY=passive` 后计算时间回到 364 µs，说明是 15 个空转线程拖慢了它，但每次调用多付约 300 µs 唤醒开销，墙钟反升到 675.4 ms。把中心距离也拆成任务后，$S(16) = 3.99$，延迟 p50/p95 从 0.351/0.496 ms 降到 0.088/0.129 ms（P2）。

4.2 查询工作量（实验 B）

p=16，查询按原始顺序、C(q) 升序和降序排列（ground truth 同步重排）。假设线程同速的调度模型预测：排序后 static 的不均衡在多个 batch 时从 1.156 降到 1.071，单个 batch 时从 1.060 升到 1.348。

表 3: 实验 B，3 轮中位数。W_t 列中 static 行依次为 batch=64 和 1024，其余两行为 batch=64。各线程计数之和恒为 2,284,819，等于总候选数。

T (ms)：原始 / 升序 / 降序	batch=64	batch=1024（单个 batch）	W_t 不均衡（原始→升序）
omp1 static	58.9 / 56.6 / 57.0	50.4 / 55.5 / 58.3	1.10→1.06；1.17→1.98
omp1 dynamic:1	53.6 / 53.0 / 53.6	46.5 / 47.4 / 45.8	1.28→1.11
omp2	52.4 / 53.4 / 54.1	46.9 / 48.7 / 46.1	1.20→1.28

单个 batch 时，排序把重查询集中给最后几个线程，static 稳定慢 10–16%（3 轮中位数；单轮 6–17%）；多个 batch 时模型预测的 7% 收益淹没在噪声里（P4）。dynamic 与 omp2 的时间不均衡只有 1.00–1.05，工作量不均衡却有 1.1–1.3，因为快线程领到了更多工作（各线程速度相差 1.3–1.7 倍）：本机上线程速度的差异比查询工作量的差异更影响负载均衡。

4.3 任务大小（实验 C）

omp2，p=16；grain 取 64/128/256/1024/4096 时，平均每查询 35.4/17.9/9.2/2.6/1.04 块。

grain	64	128	256	1024	4096
batch=1 时的 S	0.87	**0.90**	0.89	0.77	0.69
batch=64 时的 S	7.15	7.30	7.36	7.29	7.15

batch=1 时块太大就失去查询内并行、块太小则任务开销上升，最优在 128–256；batch=64 时查询间并行已足够，各 grain 差异不到 3%（P5，图见附录 D）。临时空间每查询最多 5.7 KB，合并约为块数×k 次插入，可以忽略，块越多代价主要在任务调度。cutoff 取 2048、4096 时变慢 14–25%（≤1024 时无影响），因此不设；critical 对照（omp3）比 omp2 慢 1.75 倍。

4.4 搜索范围（实验 D，图见附录 D）

nprobe 取 1/8/32/64 时 Recall@10 为 0.269/0.697/0.918/0.967。nprobe 从 8 降到 1，候选数降为 1/8，串行 QPS 只升 **1.59** 倍，Recall 却跌到 0.27（P6 成立）；这部分提速来自搜索范围缩小，与并行无关。拟合 $t = 234.5\,\mu s + 68.3\,\text{ns} \cdot \bar{C}$ 推出 $f_{sel} = 0.606$，与 P0 实测的 0.623 一致，两种方法互证。nprobe 越大 S 越低（7.8→4.5）：nprobe=32 时候选向量的有效读带宽为 29.5 GB/s，约为读带宽峰值（36.7 GB/s）的 80%。

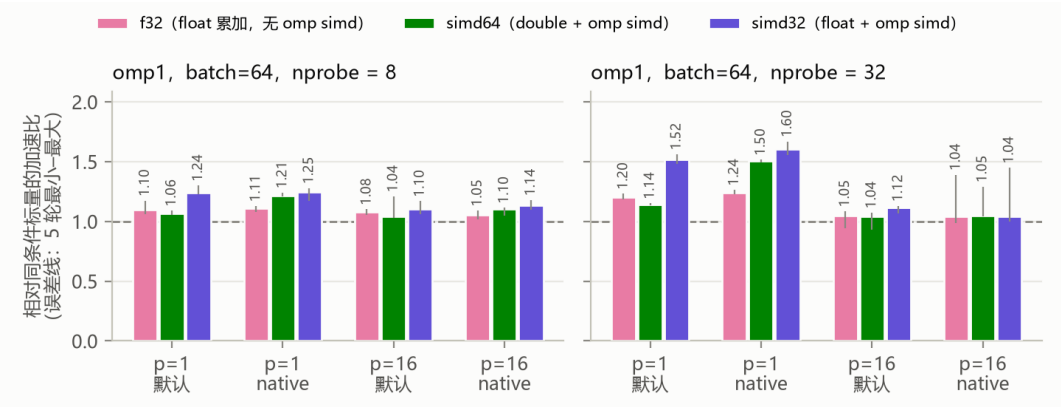


图 2: 实验 E：相对同条件标量距离的加速比（omp1，batch=64）。采用区组设计：同一条件的 4 种距离背靠背运行，组内取比值，再取 5 轮中位数。

4.5 SIMD（实验 E）

向量化证据（GCC 报告与反汇编）：默认选项下公共的 double 循环未向量化（`missed`），只有 `subsd/mulsd/addsd`；simd64/simd32 主循环为 `subpd/mulpd/addpd` 与 `subps/mulps/addps`，`-march=native` 下改用 ymm。**去掉 `omp simd` 的 f32 仍被自动向量化**：减法和乘法打包，加法仍是按原顺序的标量 `addss`，所以”f32 对 simd32”比较的是”能否重排加法”，不是”有无 SIMD”。**结果**（P7）：p=1 时 simd32 整体快 1.24 倍（nprobe=8）和 1.52 倍（nprobe=32），按 Amdahl 反推扫描本身都只快约 2 倍（原预测 3–7 倍偏高）；nprobe=32 时换成 float 贡献 1.20 倍，允许重排加法再贡献 1.26 倍。p=16 时只快 1.04–1.14 倍，因为 nprobe=32 时读带宽已达峰值的 82–93%。E 首次运行受后台负载漂移影响（轮间差 10–75%）已作废，改用区组设计重测。

4.6 OpenMP 与 std::thread（实验 F）

两者划分方式相同。batch=16 时 std::thread 慢 28%（85.3 对 66.4 ms，3 轮方向一致），batch 为 64、256 时差异在 ±3% 内；过原点回归得到每次调用多 **288 µs**（P8）。OpenMP 的线程池让短任务不必反复建线程，`schedule` 让动态调度只改一个参数；需要自己管理线程生命周期、任务队列或线程间通信时（如常驻检索服务、流水线），std::thread 加自建线程池更灵活，但这些机制都要自己实现。

5 perf 分析

采集范围：`perf stat --delay=-1 --control fifo:ctl,ack` 启动时计数器关闭；程序在加载、参考结果和预热完成后经 FIFO 发 `enable` 并等待 ack，10 次正式重复后发 `disable`（窗口内多出的输出填充和检查都是 O(Q·k)，可以忽略）。计数默认继承到子线程：OpenMP 版本的 task-clock 与检索墙钟之比为 16.0，正好等于 p，证明工作线程都被统计到了。下表在 `perf_event_paranoid=1` 时测得，取 3 轮中位数。

表 5: perf 软件事件。cycles、instructions、cache-misses、branch-misses 均为 `<not supported>`（WSL2 不暴露 PMU），因此不填写任何硬件数据。

配置（p=16，Q=1024）	CPU 利用率	task-clock/查询	上下文切换/调用	迁移/调用	缺页/调用
串行	1.00	378 µs	0.04	0	0.02
omp1 dynamic:1 / omp2，batch=64	16.04 / 16.01	854 / 858 µs	0.13 / 0.13	0	0.01 / 0.02
std::thread，batch=64	10.97	715 µs	5.50	0.59	22.02
omp2 batch=1：自旋 / passive	15.97 / 1.68	6773 / 1025 µs	0.01 / 58.03	0 / 0.16	0.004 / 0.003

解读：(1) OpenMP 的 CPU 时间是串行的 2.26 倍：统计构建测得计算时间 726 µs/查询，余下约 128 µs/查询是 barrier 处的自旋，增量的其余部分来自 §4.1 的”并发减速”。(2) std::thread 每次调用多出 5.5 次上下文切换、

0.59 次迁移和 22 次缺页（新线程的栈），对应回归得到的 288 µs。(3) batch=1 自旋时几乎没有上下文切换，但 15 个空转线程一直占着 CPU；passive 把利用率降到 1.68，代价是每次调用 58 次上下文切换（每个线程约 3.6 次休眠与唤醒），正是 §4.1 中 passive 墙钟变慢的原因。(4) 没有 cache-misses 可用，带宽改用有效读带宽与 512 MiB 顺序读探针峰值（36.7 GB/s）比较：p=16 时 nprobe=8 为 22–24 GB/s，nprobe=32 为 30–34 GB/s，后者已接近饱和。

6 结论

其一，中心选择是固定开销（62%，拟合截距 234.5 µs），同时决定了 batch=1 的并行上界、降低 nprobe 的收益上限和 SIMD 的收益上限。其二，本机上同时忙碌的线程会互相拖慢（16 线程约 1.8 倍），这才是大 batch 时加速比停在 7.4–7.9 的主因，负载不均只占约 4%；动态领取能顺应线程速度差异，static 则不能。其三，batch=1 两难：空转线程拖慢计算，让它们休眠又要付唤醒开销。

表 6: 场景推荐表（p=24 会被抢占，不推荐）。

场景	推荐配置	依据
大 batch（⩾4P），追求吞吐	omp2（grain 1024）或 omp1 dynamic:1，p=16	S=7.9 / 7.4；时间不均衡 ⩽1.05；对查询顺序不敏感
单查询，严格调用 `select_lists`	omp2，p=4，grain 128	合规版本中最高（1.23）；p=16 时反降到 0.93
单查询，低延迟（探索）	omp2 + 中心距离拆分，p=16	p50 延迟 0.088 ms（串行 0.351），S=3.99
距离函数（所有场景）	simd32（经精确性检查）	结果逐位相同；p=1 时快 1.24–1.52 倍，p=16 时快 1.10–1.12 倍
高召回（nprobe ⩾ 32）	omp1 + simd32，8–16 线程	受带宽限制（达峰值的 80–93%），再加线程收益很小
不推荐	omp3；cutoff > 1024；单个 batch 内用 static 处理排序后的查询	分别慢 1.75 倍、14–25%、10–16%

bug 与负优化：统计插桩在 `default(none)` 下引用全局数组导致编译失败，改为通过函数访问；正确性脚本的计数在管道子 shell 中，退出码恒为 0；实验 E 首轮数据被漂移污染，作废重测。batch=1、p=16 的 omp2，passive 等待策略，小任务阈值，在单个 batch 内对查询排序，都让结果变慢。**局限**：索引是自己训练的，绝对数字不能直接与同学比较；没有硬件计数器，“并发减速”的来源只是推断；测量受 Windows 后台负载影响，因此用多轮中位数和区组设计。**扩展性**：大 batch 在 16 个物理核以内可以扩展，nprobe 增大后转为受带宽限制；单查询要继续提速，需要常驻、唤醒快的工作线程，或把中心选择也纳入并行和 SIMD（后者须先证明选出的列表不变）。

7 AI 使用声明与参考资料

AI 使用声明：本实验使用了 Claude（Anthropic，通过 Claude Code 使用 Claude Opus 5.5 模型），完成了自建数据与索引，实现全部 OpenMP 策略、SIMD 距离和 std::thread 版本，扩展 harness，编写测试、实验、统计、作图和 perf 脚本并运行实验，起草本报告。方案决策由本人在三个检查点作出：CP1 把中心距离拆分作为探索写入、omp1 用 dynamic:1；CP2 定 grain 为 128（batch=1）和 1024（batch=64），cutoff=0；CP3 以成本账为主线并加入场景推荐表。数据都可以由仓库中的脚本和 `results/` 复现，已由本人核对；对话截图见附录 F。

参考资料：[1] Faiss indexes，https://github.com/facebookresearch/faiss/wiki/Faiss-indexes；[2] OpenMP 5.2 taskloop / taskgroup / SIMD，https://www.openmp.org/spec-html/5.2/openmpse74.html、https://www.openmp.org/spec-html/5.2/openmpse92.html、https://www.openmp.org/spec-html/5.2/openmpse60.html；[3] perf-stat(1)，https://man7.org/linux/man-pages/man1/perf-stat.1.html；[4] H. Jégou et al. Product Quantization for Nearest Neighbor Search. TPAMI 2011，https://doi.org/10.1109/TPAMI.2010.57（SIFT1M：http://corpus-texmex.irisa.fr/）；[5] GNU libgomp 手册，https://gcc.gnu.org/onlinedocs/libgomp/。

附录

A　实验 A 完整数据（单元格内依次为 T (ms) / S / E；batch=1 时附 p50/p95 延迟，单位 ms）

batch = 64

表 7: 串行 T = 381.2 ms。

p	omp1	omp2
1	388.4 / 0.98 / 0.98	397.2 / 0.96 / 0.96
2	193.6 / 1.97 / 0.98	196.7 / 1.94 / 0.97
4	105.6 / 3.61 / 0.90	106.8 / 3.57 / 0.89
8	64.9 / 5.87 / 0.73	64.3 / 5.93 / 0.74
16	51.4 / 7.42 / 0.46	48.1 / 7.92 / 0.50
24	69.0 / 5.52 / 0.23	54.5 / 7.00 / 0.29

batch = 1

表 8: 串行 T = 378.3 ms，p50/p95 延迟 0.351/0.496 ms。

p	omp1	omp2	omp2+拆分
1	393.2 / 0.96 / 0.96 （0.366/0.518）	417.6 / 0.91 / 0.91 （0.388/0.572）	424.7 / 0.89 / 0.89 （0.394/0.568）
2	392.4 / 0.96 / 0.48 （0.364/0.519）	329.6 / 1.15 / 0.57 （0.309/0.421）	224.8 / 1.68 / 0.84 （0.210/0.303）
4	382.7 / 0.99 / 0.25 （0.357/0.498）	308.5 / 1.23 / 0.31 （0.287/0.403）	136.6 / 2.77 / 0.69 （0.127/0.181）
8	386.3 / 0.98 / 0.12 （0.359/0.512）	318.2 / 1.19 / 0.15 （0.276/0.456）	105.9 / 3.57 / 0.45 （0.101/0.136）
16	386.0 / 0.98 / 0.06 （0.359/0.511）	407.6 / 0.93 / 0.06 （0.419/0.503）	94.8 / 3.99 / 0.25 （0.088/0.129）
24	388.3 / 0.97 / 0.04 （0.362/0.516）	786.2 / 0.48 / 0.02 （0.458/2.633）	166.4 / 2.27 / 0.09 （0.095/0.469）

B　数据与环境

自建数据的文件清单、md5 和训练参数见 `data_manifest/MANIFEST.json`，生成脚本是 `scripts/prepare_data.py`。环境的完整记录见 `results/env.txt`。所有命令、原始数据和推导过程见 `实验日志.md` 与 `results/`。

C　复现命令

```
make && make student_test && make student_test_asan          # 编译与单元测试
bash scripts/check_correctness.sh                            # 真实数据正确性（E0）
bash scripts/profile.sh                                      # P0 分阶段画像
PY=lab2/.venv/bin/python                                     # 需安装 numpy pandas matplotlib tabulate
$PY -I scripts/bench.py A --rounds 3                         # 其余：A_sched A_wait B C C_cutoff D F
$PY -I scripts/bench.py E_blocked --rounds 5                 # 实验 E（区组设计）
bash scripts/stats_B.sh && python3 -I scripts/model_B.py     # 实验 B 的统计与模型
bash scripts/vecreport.sh && make bw_probe && ./bw_probe     # 向量化证据、读带宽
$PY -I scripts/perf_ctl.py --rounds 3                        # 需 perf_event_paranoid <= 1
$PY -I scripts/summarize.py <实验名> && $PY -I scripts/plot.py A C D E
```

D　实验 C、D 的图

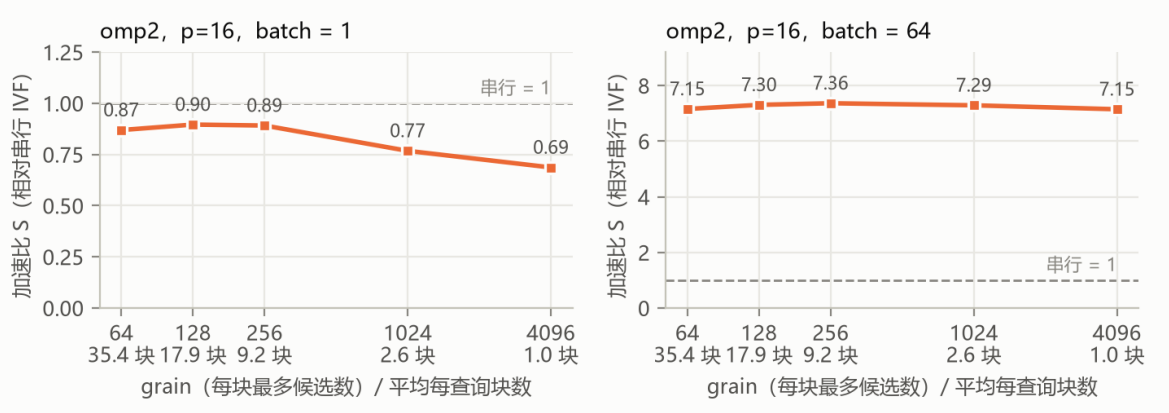


图 3: 实验 C：omp2，p=16。横轴第二行为平均每查询块数。

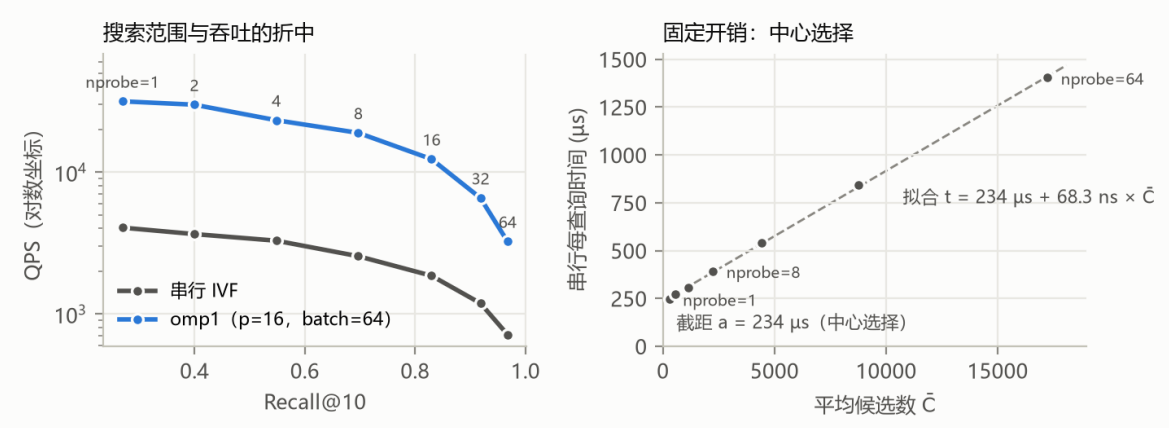


图 4: 实验 D。左：QPS 与 Recall@10 的折中（点旁数字为 nprobe）。右：串行每查询时间对平均候选数做线性拟合，截距即中心选择的固定开销。

E　正确性运行截图

（待本人运行 `bash scripts/check_correctness.sh` 后截图插入。文字版结果见 `results/e0_correctness.txt`，101 次全部 PASS。）

F　AI 对话截图

（待本人插入。）